Киберсигурност, машинно обучение и изкуствен интелект

Доц. М. Иванова

https://cset.georgetown.edu/wp-content/uploads/Machine-Learning-and-Cybersecurity.pdf

Машинно обучение - дефиниции

Машинното обучение е част от научното направление *Изкуствен интелект*, която изучава алгоритми и математически модели, използвани от компютърните системи за подобряване на тяхната ефективност при решаване на определена задача.

Алгоритмите за машинно обучение изграждат математически модел по примерни данни, наречени „*обучаващи данни*“, за да прогнозират или да вземат решения, без да са изрично програмирани за това.

Wikipedia: https://en.wikipedia.org/wiki/Machine_learning

Машинно обучение - дефиниции

Терминът **машинно обучение** е въведен от Артър Самюел през 1959 г.

“Машинното обучение е област на изследване, което се свързва с възможността на компютрите да учат без да са изрично програмирани за това.” А. Самюел

Arthur Lee Samuel

Born	December 5, 1901 Emporia, Kansas
	July 29, 1990 (aged 88) Stanford, California
nship	United States
mater	MIT (Master 1926) College of Emporia (1923)
Known for	Samuel Checkers-playing Program Alpha–beta pruning (an early implementation) Pioneer in Machine Learning [1] TeX project (with Donald Knuth)
Awards	Computer Pioneer Award (1987) [2]
Scientific career	
Fields	Computer Science
Institutions	Bell Laboratories (1928) University of Illinois (1946) IBM Poughkeepsie Laboratory (1949) Stanford University (1966)

Машинно обучение - дефиниции

Машинното обучение е процес на преобразуване на данните в модели.

Машинното обучение се свързва с това, как да се конструират компютърни програми, които автоматично да се подобряват чрез опит. (Tom Mitchell, Professor Machine Learning, Carnegie Mellon University)

Машинно обучение - дефиниции

Традиционен процес на програмиране

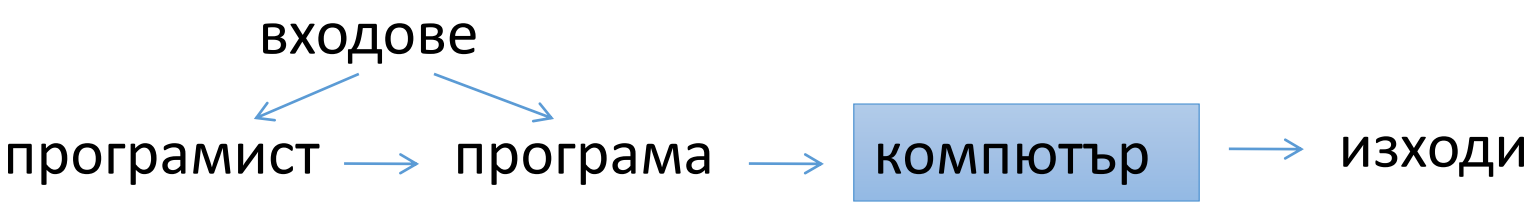

Машинно обучение

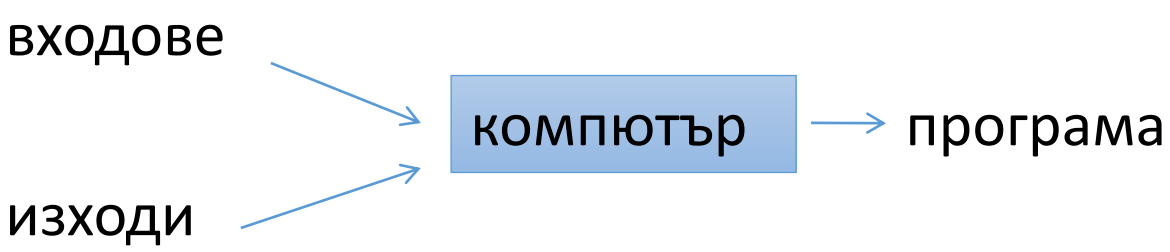

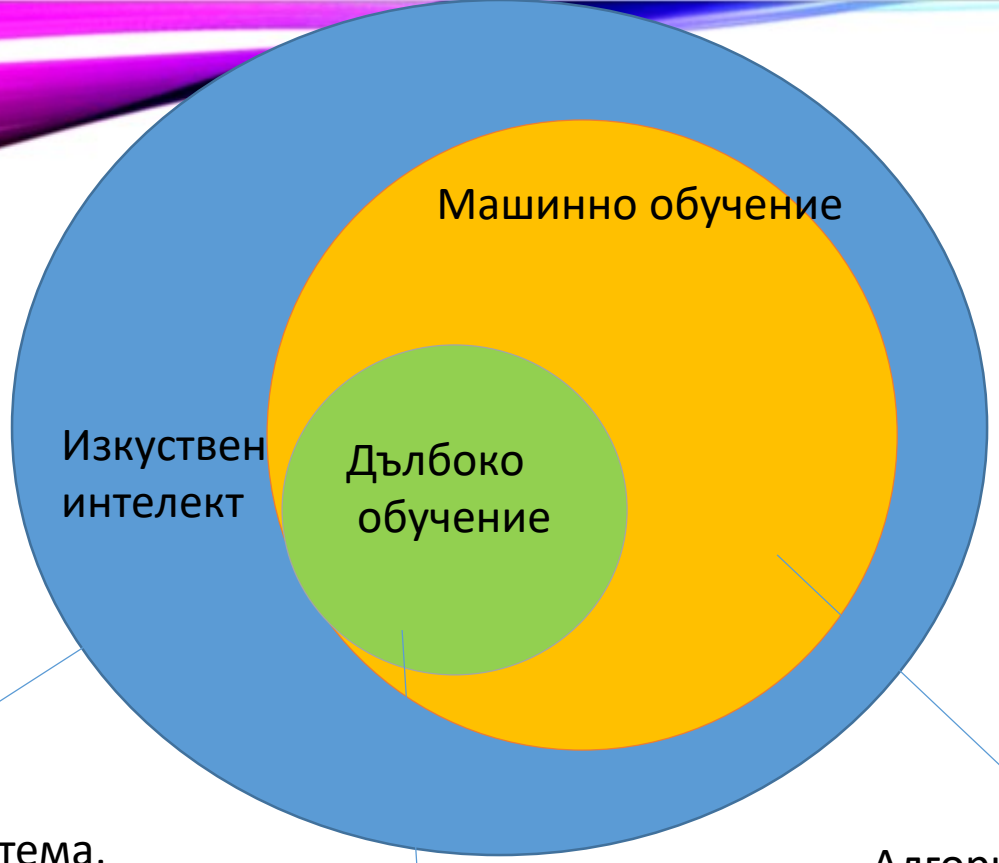

Небиологична система, която е интелигентна чрез прилагане на правила, компютър извършва дейности, характерни за човек

Дълбокото обучение е част от ИИ, занимаващата се с алгоритми, които се основават на изкуствени невронни мрежи

Алгоритми, които автоматично научават модели/правила/ представяния от данни/примери

Видове машинно обучение

Контролирано обучение (supervised learning) - изгражда се математически модел въз основа на входни данни и изходни резултати – целта е да се извърши класификация или прогноза

- **Машина с поддържащи вектори**
- **Линейна регресия**
- **Логистична регресия**
- **Бейсов класификатор**
- **Дървета с решения**
- **К-най-близкия съсед**
- **Невронни мрежи**
- **Други**

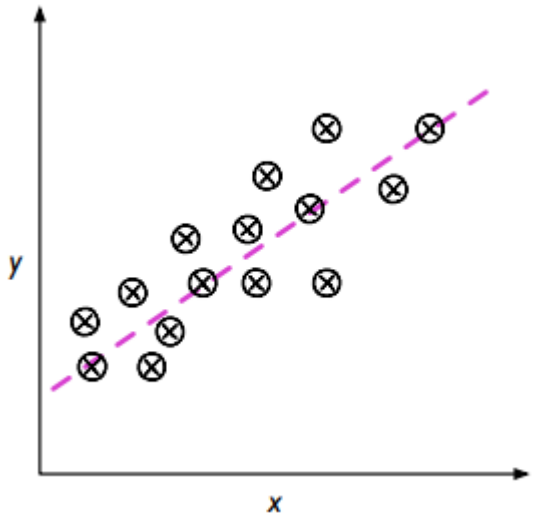

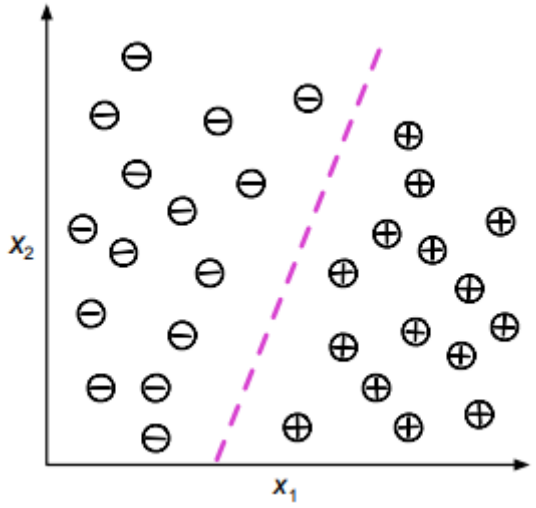

Видове машинно обучение

- **Неконтролирано обучение** (Unsupervised learning) - математическите модели се построяват въз основа на входни данни, които не съдържат указания за желаните резултати – целта е да се окрият определени зависимости/структури в набора от данни
- Използват се алгоритми за:
  - Клъстеризация
  - Идентифициране на аномалии
  - Построяване на самоорганизиращи се карти
  - Моделиране на прогнозни вероятности

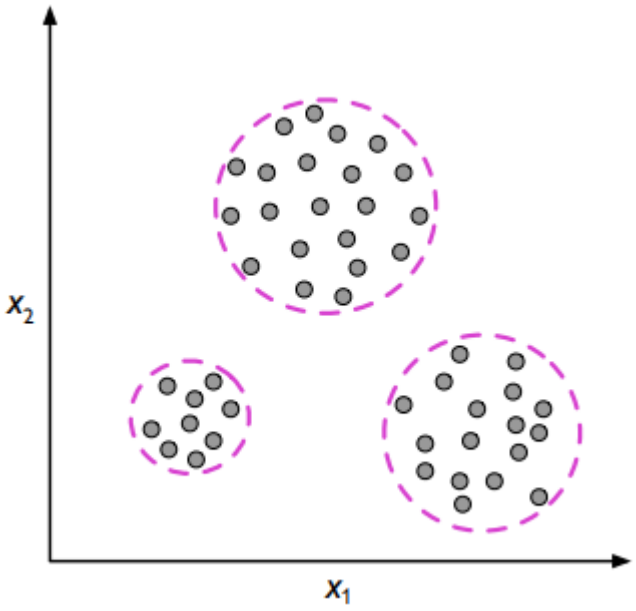

Видове машинно обучение

- **Алгоритми за частично контролирано машинно обучение** (комбинация от контролирано и некотролирано обучение) – математическият модел се построява въз основа на непълни обучаващи данни, като за част от които не е зададен желаният резултат – целта е да се подобри прогнозата чрез използване на допълнително примери с входни данни
  - Генеративни модели
  - Графови модели
  - Евристични подходи

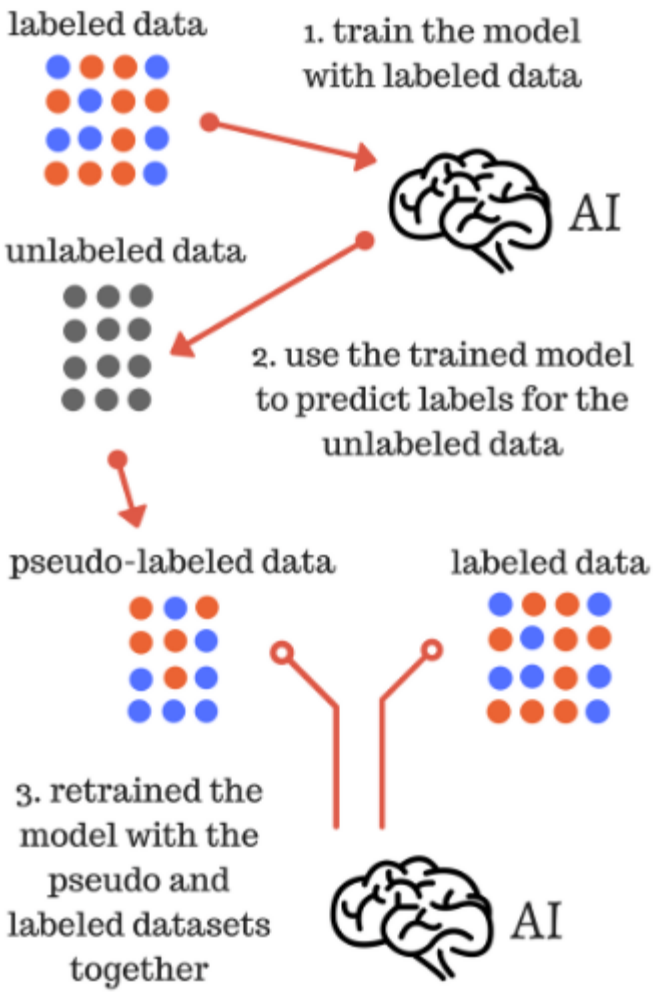

Видове машинно обучение

Обучение с утвърждение (Reinforcement Learning) – не са необходими примерни решения на поставените проблеми – извършват се пробни действия, като правилните действия се утвърждават, а неправилните се избягват

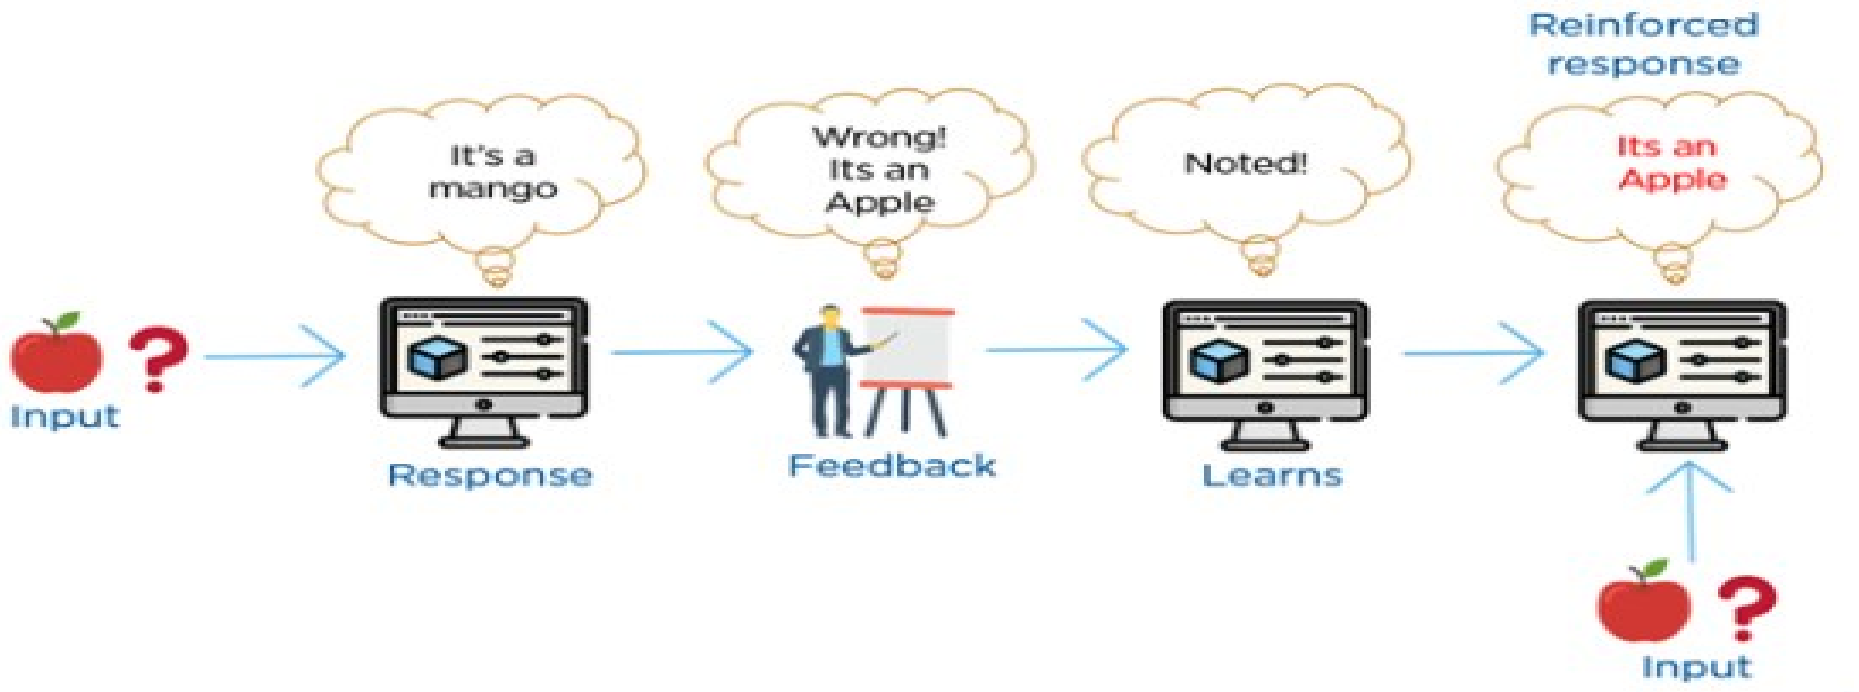

	Преди 1990	1990	2000	След 2010
Откриване на спам	1978 – първи спам email	1996 – първи подход за блокиране на спам	• 2002 – за първи път се използва ML за откриване на спам • 2003 – първи опити за регулиране на спам в САЩ	• ML за откриване на спам, широко вградено в email услугите • Поява на базирани на дълбоко обучение класификатори
Откриване на проникване	• 1980 – първи системи за откриване на проникване • 1986 – Системи за откриване на аномалии чрез комбиниране на експертни правила и статистически анализ	• Началото на 90-те – невронни мрежи за откриване на проникване • 1999 – DARPA създава набори с данни за изучаване на системите за откриване на проникване	ML е проучено допълнително като възможен инструмент за откриване на проникване, базирано на злоупотреба и базирано на аномалии	• В края на 2010-те - Поява на широкомащабни, базирани на облак системи за откриване на проникване • Дълбокото обучение е изследвано за откриване на проникване
Откриване на зловреден софтуер	• Началото на 80-те – първи открити вируси • Края на 80-те – основани са първите антивирусни компании	• Начало на 90-те –първи полиморфни вируси • 1996 – IBM започва изучаването на ML за откриване на зловреден софтуер	• Началото на 2000-те - първи метаморфни вируси • Изследвани са голям брой традиционни методи на ML за откриване на зловреден софтуер	• Възход на антивирусен софтуер от следващо поколение • Поява на антивирусни компании, фокусирани върху ML

Откриване на спам

- Ранни методи - сравнително прости:
  - първо събира се голямо количество имейли,
  - етикират се като спам или не
  - за всяка дума в email-ите се изчислява вероятността даден email да е спам, ако съдържа тази дума.
- Когато пристигне нов имейл, вероятностите, свързани с всяка от неговите думи, могат да се използват за изчисляване на риска имейлът да е спам, а имейлите с рискови резултати над предварително зададен праг могат да бъдат автоматично блокирани.
- По-добри класификатори на спам се изграждат чрез извличане на повече технически подробности от хедъра на пощата, като IP адреси и информация за сървъра, или чрез третиране на думи, които се появяват в реда subject.
- Могат да се използват по-добри алгоритми които разпознават фрази или синоними, вместо да третират всички думи като независими една от друга.
- Някои компании са разработили изключително сложни детектори за нежелана поща, които могат, наред с други неща, да проследят минали имейл взаимодействия на потребителя, за да маркират аномални контакти или да използват модели за дълбоко обучение, за да определят дали имейлите с маркетингова цел се изпращат от автентични компании или не.

Откриване на проникване

- **Системите за откриване на проникване** се опитват да открият наличието на неоторизирани дейности в компютърни мрежи, обикновено чрез фокусиране върху профили на поведение и търсене на признаци на злонамерена дейност.
- **Системите за откриване на проникване** обикновено се класифицират като:
  - базирани на злоупотреба - атаките се идентифицират въз основа на тяхната прилика с вече наблюдавани атаки
  - базирани на аномалия - изгражда се базова линия на „нормално“ поведение и всичко, което не съответства на тази базова линия, се маркира като потенциална атака
- И двата подхода могат да използват различни ML методи.

Откриване на проникване

- Най-простите форми на **базирано на злоупотреба откриване** разчитат на известни индикатори за компрометиране, за да открият срещани преди това заплахи. Например, ако една организация е разбрала за злонамерен софтуер, който се опитва да се свърже с конкретен уеб сайт, киберзащитниците могат да напишат проста система за откриване, която дава предупреждение всеки път, когато машина се опитва да се свърже с този уеб сайт.
- **Базираното на злоупотреба откриване** – обикновено има висока скорост на обработка и ниски нива на фалшиви положителни резултати, което му позволява бързо и точно да идентифицира злонамерени събития. Тази форма на откриване обаче може да следи само за известни заплахи, осигурявайки недобра защита срещу нови атаки.
- **ML** може да се използва за автоматизиране на някои форми на откриване, базирано на злоупотреба, като позволи на системата да „научи“ как изглеждат различни видове атаки.
- Ако има много примери за минали атаки, **класификатор от контролирано машинно обучение** може да бъде обучен да идентифицира сигналните знаци за различни видове атаки, без да е необходимо хората да генерират конкретни списъци с правила, които биха задействали предупреждение.
- От 1999 г. изследователите се опитват да генерират профили на мрежовия трафик на различни типове атаки, така че класификаторите на ML да могат да се научат как да идентифицират по-рано наблюдавани атаки.

Откриване на проникване

- Преглед на експериментални резултати през 2018 г. предполага, че дълбокото обучение не е по-точно при откриване, базирано на злоупотреба в сравнение с предишните подходи за машинно обучение.
- Изследователите често показват, че най-успешните алгоритми за машинно обучение са **ансамблови модели** или модели, които класифицират чрез използване на множество класификатори, които „гласуват“ за една класификация.

Откриване на проникване

- За разлика от откриването, базирано на злоупотреба, откриването, базирано на аномалии, идентифицира подозрително поведение, без да прави конкретни сравнения с минали атаки.
- Този тип система за откриване е по-вероятно да използва методи от неконтролирано машинно обучение за групиране на „нормален“ трафик в рамките на мрежа и да предупреждава като подозрителна всяка дейност, която се отклонява от този модел.
- На теория откриването, базирано на аномалии, може да идентифицира нови атаки – един от най-трудните аспекти на киберсигурността.
- Изследванията са насочени към намиране на начини за подходящо базово очертаване на „нормалния“ трафик за дадена мрежа, тъй като дори нормалният трафик може да бъде силно променлив и лошо настроената система за откриване на проникване ще генерира много фалшиви положителни резултати.

Откриване на проникване

- Въпреки че откриването, базирано на аномалии, може да бъде много ефективно при проследяване на отделна машина или потребител, то често се използва за идентифициране на подозрително поведение в мрежата.
- Може да се генерират много фалшиви положителни резултати, което говори за трудността да се дефинира „нормален“ трафик достатъчно строго, за да се открият всякакви аномалии, но достатъчно свободно, че нито едно законно поведение да не бъде маркирано като аномално.
- Поради трудностите, свързани с откриване на аномалии, много организации го използват само като допълнение към стандартните системи за откриване, базирани на злоупотреба.

Откриване на зловреден софтуер

- Докато системите за откриване на проникване наблюдават поведението на системата или мрежата, за да идентифицират признаци, че мрежата е атакувана, **системите за откриване на зловреден софтуер** изследват конкретни файлове, за да определят дали са злонамерени.
- Чрез поддържане на дълги списъци със сигнатури на злонамерен софтуер и извършване на редовни сканирания, тези антивирусни продукти се опитват да определят дали някакви файлове на машината са свързани с тези известни дефиниции.
- За съжаление, тези методи за откриване могат лесно да бъдат избегнати чрез полиморфни или метаморфни вируси – типове зловреден софтуер, който променя собствения си код всеки път, когато се разпространява – като по този начин се гарантира, че различните версии ще имат различни сигнатури.
- Въпреки че традиционните техники за откриване все още могат да бъдат адаптирани за откриване на полиморфен или метаморфен злонамерен софтуер, те стават все по-сложни, изискващи интензивни изчисления, и в същото време атакуващите се усъвършенстват.

Откриване на зловреден софтуер

- **Машинното обучение** превъзхожда идентифицирането на споделени характеристики между записи, които не могат да бъдат класифицирани с помощта на прости правила.
- Още през 1996 г. изследователи от IBM започват да проучват използването на невронни мрежи за класифициране на вируси в сектора за зареждане - специфичен тип вирус, който е насочен към инструкциите на машината за зареждане.
- В началото на 2000 се изследва използването на **статистически модели и стандартни ML класификатори** за откриване на зловреден софтуер.
- Прилага се и **дълбоко обучение** за откриване на зловреден софтуер, характеризиращо се с много предимства, като например възможността за извличане на знание от необработени данни с по-малка човешка намеса.
- И все пак, както при откриването на проникване, някои експериментални резултати показват, че ML класификатори продължават да се използват толкова, колкото и по-напредналите методи на дълбоко обучение, когато се обучават върху едни и същи данни.

Киберсигурност и изкуствен интелект

- Четири вида методи и техники от машинно обучение и изкуствен интелект, които се изследват през последните години:
  - 1) дълбоко обучение (deep learning);
  - 2) обучение с утвърждение (reinforcement learning);
  - 3) генеративни състезателни мрежи (GAN- Generative Adversarial Network); и
  - 4) големи езикови модели (large language models).
- Именно комбинацията от архитектури за дълбоко обучение с други подходи – като GAN, системи за обучение с утвърждение или големи езикови модели е предпоставка за напредъка в киберсигурността.

Киберсигурност и изкуствен интелект

Дълбокото обучение е обща AI архитектура, моделирана чрез невронни мрежи. Може да се адаптира за много задачи в областта на киберсигурността.

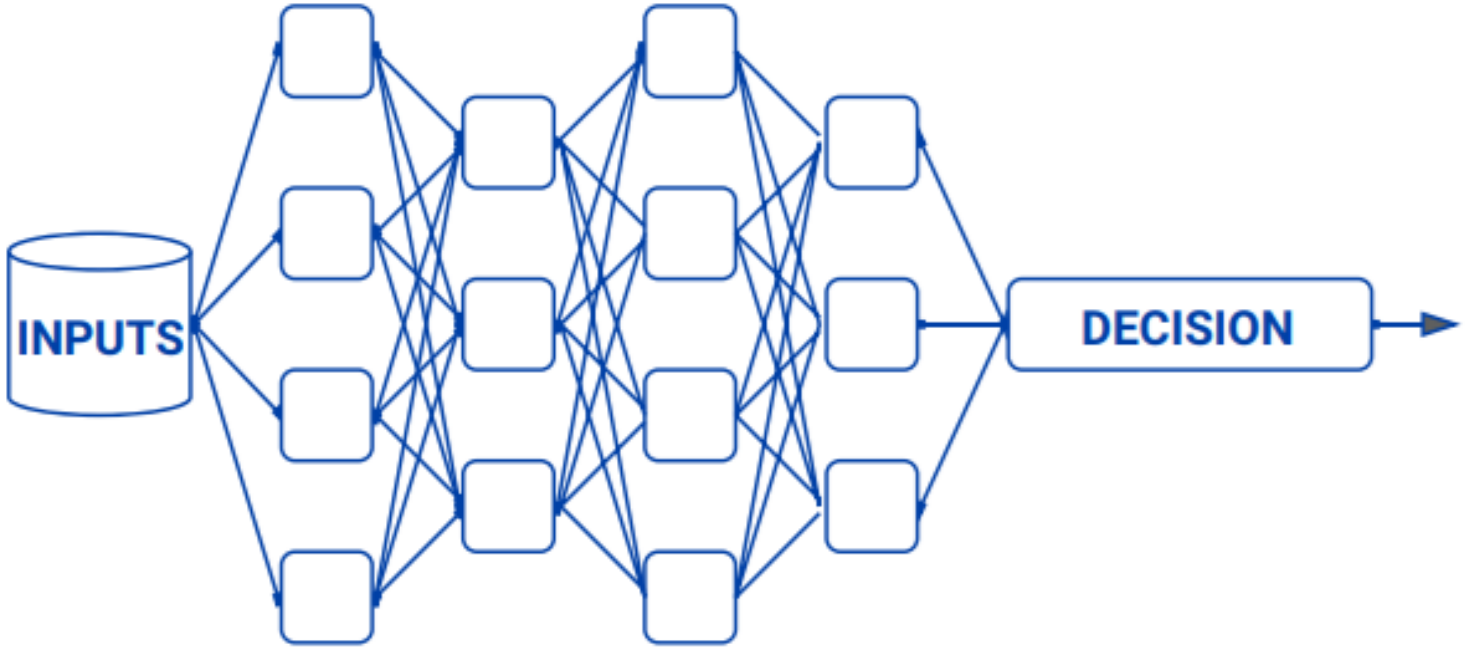

Киберсигурност и изкуствен интелект

Задача 1. В **системи за обучение с утвърждение**, където AI агентите се учат как да взаимодействат със средата си.

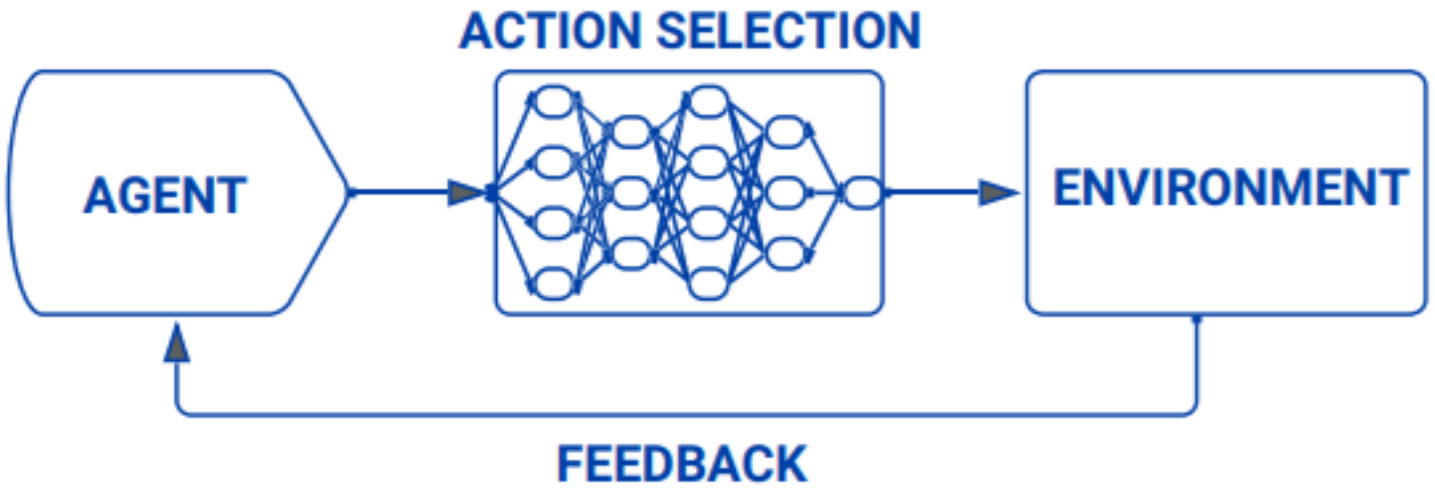

Киберсигурност и изкуствен интелект

Задача 2. **Генеративни състезателни мрежи** , където генераторът се научава как да произвежда изходни синтетични данни, които се подават към дискриминатора, който различава реалните от синтетичните данни.

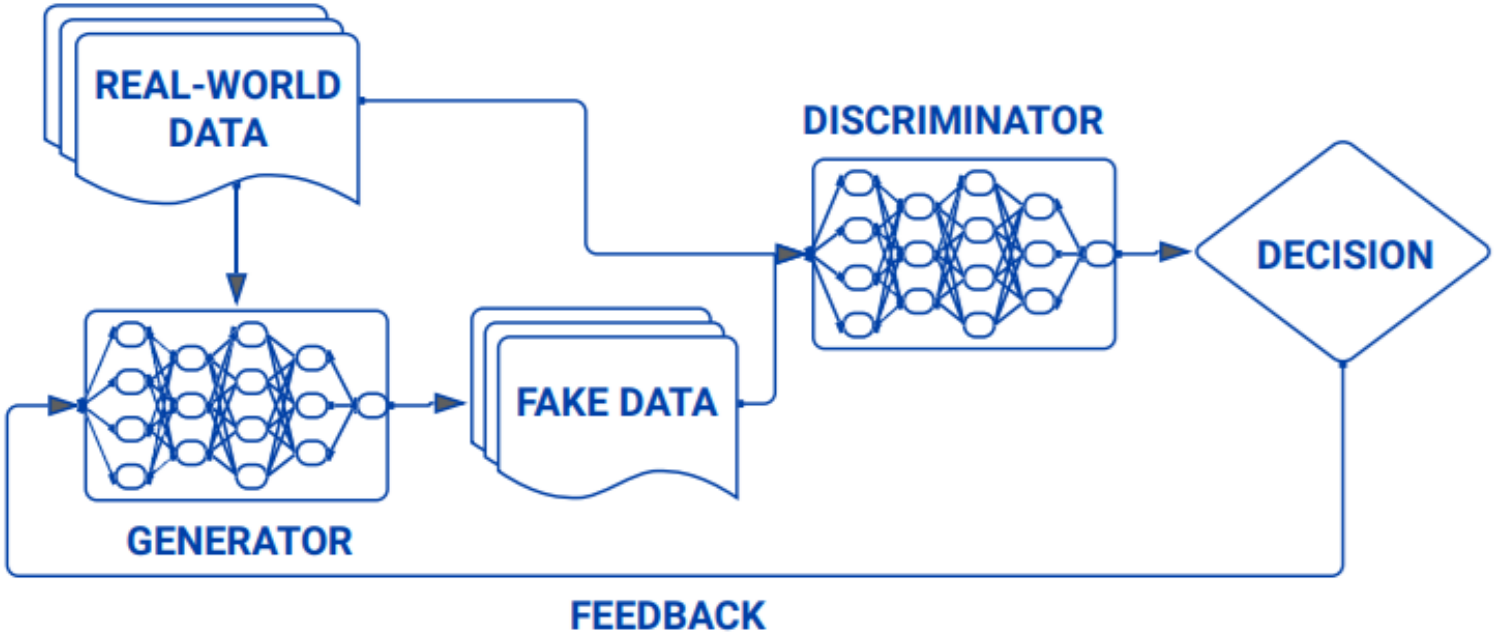

Киберсигурност и изкуствен интелект

Задача 3. **Големи езикови модели**, които могат да изпълняват широк спектър от задачи, свързани с езика.

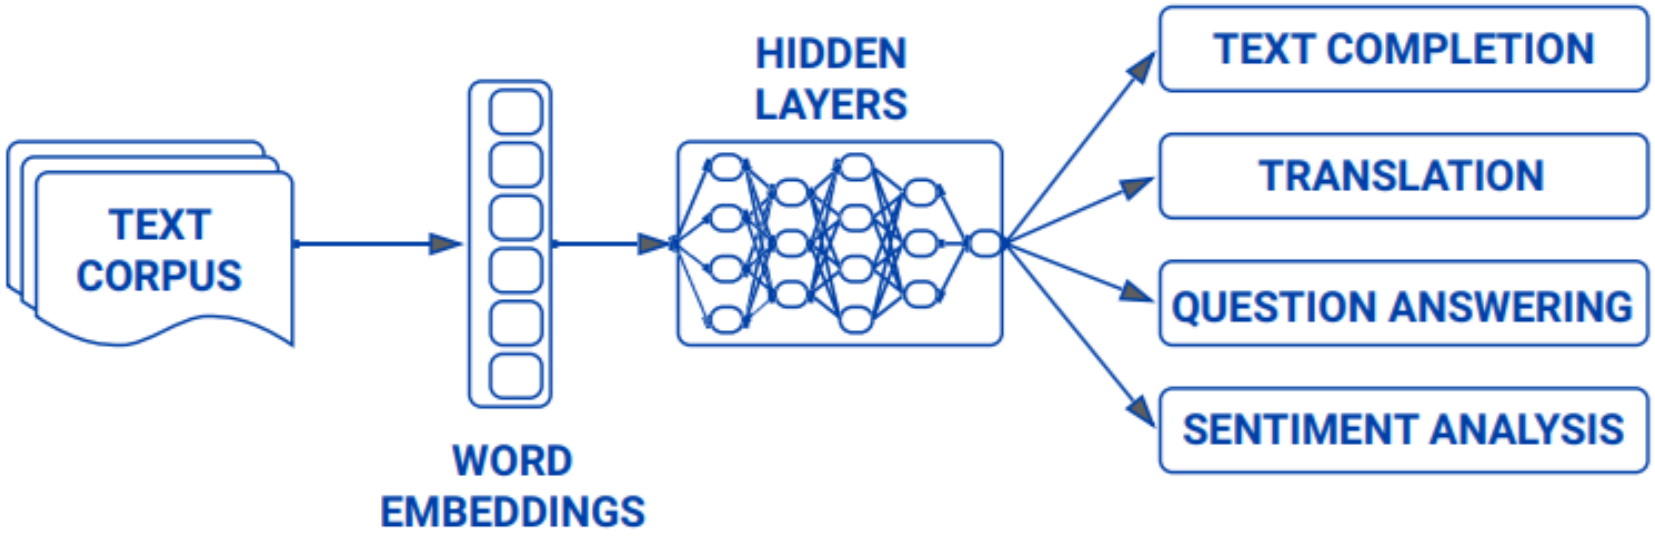

Приложения с изкуствен интелект за превенция

Задача по киберсигурност	Нови приложения на AI	Значимост на задачата	Трансформиране потенциала на нови AI
Фъзинг (fuzzing)	Дълбоко обучение	Висока	Средно-високо
Пен тестване	Обучение с утвърждение	Висока	Средно-високо
Сортиране на грешки и класификация	Обработка на естествен език, традиционни методи за ML	Средна	Средно
Оценка тежестта на уязвимостта	Обработка на естествен език, традиционни методи за ML	Средна	Средно-ниско

Приложения с изкуствен интелект за превенция

- **Превенцията** в киберсигурността е свързана с откриване и коригиране на уязвимости.
- Отдавна има интерес към изграждане на инструменти, които могат автономно да намират и коригират нови уязвимости, но ML едва наскоро започна да се използва за тази цел.
- Съвсем наскоро, когато през 2016 г. спонсорираното от DARPA състезание Cyber Grand Challenge, най-обещаващите пътища за автоматизирано откриване на уязвимости все още разчитаха на внимателно програмирани системи без използване на методи за ML. Въпреки че няколко отбора в това състезание се опитаха да използват ML за идентифициране на софтуерни уязвимости, Mayhem – програма победител – в крайна сметка не използва ML в своите модули за откриване на уязвимости.
- Вместо това Mayhem използва два по-често срещани метода за откриване на уязвимости:
  - Първо, машина за символично изпълнение анализира програми чрез изграждане на представяния на тяхната логика на изпълнение, като по този начин научава как може да се задействa потенциално поведение, предизвикващо срив.
  - Второ, той използва fuzzers, които подават модифицирани и полуслучайни входове към програма, за да определят дали причиняват някакви неочаквани състояния.
- В Mayhem и двата елемента са програмирани с помощта на традиционни, базирани на правила системи, които са комбинирани с модули, които могат автономно да пишат и внедряват пачове за открити уязвимости.

Приложения с изкуствен интелект за превенция

- Fuzzers търсят уязвимости в кода, но кибер защитниците могат също да използват тестове за проникване (или накратко pentesting), за да търсят известни уязвимости и несигурни конфигурации в мрежите.
- При пентест опитни хакери систематично изследват мрежа за уязвимости, за да идентифицират потенциални слабости.
- За големи организации, пентестовете могат да бъдат скъпи и отнемащи седмици време на служителите.
- Автоматизирани инструменти като програмата с отворен код Metasploit могат частично да компенсират тези разходи, но тези инструменти просто преминават през списък от предварително избрани, известни експлойти, за да определят дали някои машини в мрежата са уязвими към тях.

Приложения с изкуствен интелект за превенция

- **Обучение с утвърждение -** създават се AI агенти, които провеждат пентестове по стратегически начин, те могат да създават правдоподобни стратегии за различни ситуации и могат да го направят сравнително бързо, ако първо научат няколко примера за извършван пентест от хора.
- Подходите, базирани на **обучение с утвърждение**, позволяват на автоматизираните инструменти да търсят в мрежа за уязвимости много по-бързо от базираните на правила инструменти за пентест като Metasploit.
- Проучванията, изследващи използването на обучение с утвърждение за пентестове, обикновено разчитат на малки среди - често симулирани мрежи от около десет машини - с ограничен брой експлойти.
- Тъй като или сложността на средата, или броят на действията, достъпни за програмата, се увеличават, **обучението с утвърждение** може бързо да стане изчислително непосилно.
- Този проблем е предизвикателен, но не е напълно неразрешим: в друг контекст изследователите са разработили модели, които могат ефективно да намалят броя на опциите, които една програма трябва да вземе предвид.
- Ако изследователите успеят да разработят изчислително осъществими методи за симулиране на сложни мрежи и ефективен избор между много опции, програмите за обучение с утвърждение биха могли да станат важни помощни средства за пентестване.

Приложения с изкуствен интелект за превенция

- Освен намирането на уязвимости чрез автономни fuzzers и пентестове, машинното обучение може скоро да бъде в състояние да предостави инструменти, които да помогнат на защитниците да разпределят времето и вниманието си към най-належащите уязвимости.
- Въпреки че има много други начини, по които машинното обучение може да бъде използвано за превантивни цели, тук се дискутират две други приложения:
  - анализ на нови доклади за грешки и
  - оценка на сериозността на идентифицираните уязвимости.

Приложения с изкуствен интелект за превенция

- От 2005 г. изследователите проучват начини, по които ML може да се използва за **автоматично анализиране на доклади за грешки**.
- Системите за ML могат например
  - да посочват грешки на софтуерния инженер, който е най-способен да ги адресира,
  - да маркират характеристиките на зловреден софтуер въз основа на отчети, генерирани от хора, или
  - да предскажат вероятността на нов бъг, който представлява уязвимост в сигурността.
- Microsoft наскоро демонстрира, че ML може успешно да използва доклади за грешки, за да класифицира грешки като релевантни или нерелевантни за сигурността.
- Моделът на Microsoft беше обучен на повече от милион действителни доклада за грешки на Microsoft, което предполага, че някои автоматизирани форми на анализ на доклади за грешки може да са осъществими за софтуерни компании с достъп до големи количества данни за обучение.

Приложения с изкуствен интелект за превенция

- След като уязвимостите бъдат идентифицирани, защитниците имат ограничено време и ресурси, за да ги **коригират**.
- Една важна метрика, която помага на защитниците да определят сериозността на дадена уязвимост, е Общата система за оценка на уязвимостта (CVSS), която разчита на експертен анализ, за да присвои оценки за сериозност на нови уязвимости.
- Други изследователи са използвали данни за атаки, за да изградят системи за машинно обучение, които предвиждат вероятността някои уязвимости действително да бъдат използвани.
- Има някои доказателства, че когато тези **базирани на ML оценки на риска** се използват заедно с **CVSS**, организациите могат да постигнат подобни нива на коригиране на риска със значително по-малко усилия, като приоритизират своите усилия за отстраняване на уязвимостите, които е най-вероятно да бъдат използвани.
- Взети заедно, използването на ML за подобрени фъзери, пентестване, анализ на доклади за грешки и оценка на сериозността може да позволи на организациите да подобрят способността си да идентифицират и приоритизират уязвимостите.

Приложения с изкуствен интелект за откриване на атаки

Задача по киберсигурност	Нови приложения на AI	Значимост на задачата	Трансформиране потенциала на нови AI
Точно откриване	Дълбоко обучение	Висока	Ниско
Приоритизиране на предупреждения за уязвимости	Дълбоко обучение	Средно-висока	Средно
Повишаване точността на системи за откриване на атаки	GAN	Средно-висока	Средно-ниско

Приложения с изкуствен интелект за откриване на атаки

- Въпреки развитието на **дълбокото обучение**, много компании за киберсигурност продължават да използват значително по-прости ML модели днес.
- Един проблем с базираното на ML откриване е, че ML системите са уязвими на няколко вида атаки.
- Използването на ML модели отваря нови пътища за атака: самият модел трябва да бъде защитен, но защитниците също трябва да се уверят, че техните данни не са били модифицирани и че (обикновено отворен код) алгоритмите и статистическите пакети, които използват, не са били манипулирани.

Приложения с изкуствен интелект за откриване на атаки

- GAN колкото помагат, толкова и могат да се считат за заплаха за сигурността - могат да генерират синтетични и реалистично изглеждащи данни.
- Изследователите вече демонстрираха, че GAN могат да разработят стратегии за атаки, които се изплъзват на съществуващите **системи за откриване на проникване**, независимо дали са базирани на ML или не.
- GAN могат да помогнат за подобряване на системите за ML срещу тези видове по-сложни заплахи: когато **системите за откриване на проникване** са обучени с помощта на GAN могат да предвиждат потенциални противникови атаки, тяхната точност срещу противникови атаки е значително подобрена. GAN също могат да увеличат съществуващите набори от данни чрез генериране на нови данни за обучение.
- GAN-усъвършенствани набори от данни за спам и злонамерен софтуер са използвани от някои изследователски екипи за създаване на класификатори, които се представят по-добре от тези, обучени само върху данни от реалния свят.

Приложения на изкуствен интелект при отговор и възстановяване

Задача по киберсигурност	Нови приложения на AI	Значимост на задачата	Трансформиране потенциала на нови AI
Ангажиране на противника	Обучение с утвърждение	Висока	Средно-ниско
Защита на динамична цел	Обучение с утвърждение	Висока	Средно-високо

Приложения на изкуствен интелект при отговор и възстановяване

- **Отговорът и възстановяването** е динамичен и непрекъснат процес, който не се разделя толкова лесно на отделни компоненти, което прави много по-трудно изграждането на инструменти за ML, които могат адекватно да автоматизират вземането на решения.
- През последните години някои автори започнаха да идентифицират по-целенасочени роли, които AI/ML системите могат да играят в процеса на реакция и възстановяване.
- Доклад от 2020 г. на *Националния съвет за наука и технологии* на САЩ идентифицира най-малко два конкретни начина, по които AI може да подпомогне **процеса на реакция и възстановяване**:
  - чрез точно категоризиране на текущи атаки и избор на подходяща първоначална стратегия за отговор или
  - чрез автоматизиране на решението за изолиране на машини от мрежа или налагане на ограничения на потребителски машини за задържане на инфекции.

Приложения на изкуствен интелект за активна защита

Задача по киберсигурност	Нови приложения на AI	Значимост на задачата	Трансформиране потенциала на нови AI
Подвеждащо генериране на документи	NLP, GAN	Средна-ниска	Високо
Динамичен хънипотинг	Обучение с утвърждение	Средна	Средно-високо
Автоматизиран фишинг	NLP, Обучение с утвърждение	Ниска	Средно-високо
Заплаха дарк уеб	NLP	Средна	Средно
Изучаване методите на атакуващия	NLP, традиционни ML методи	Средна-ниска	Средно
Деанонимизиране на код	NLP	Ниска	Средно-ниско

Приложения на изкуствен интелект за активна защита

- **Измама**
- Една от основните **мерки за активна защита**, достъпна за киберзащитниците, е **измамата**: умишлено фалшифициране на нещо, за да подведе и забави атакуващите.
- Въпреки че тази стратегия изглежда опростена, тя може да има големи оперативни ползи.
- Измамното поведение на мрежа например се използва за изучаване поведението на атакуващ.

Приложения на изкуствен интелект за активна защита

- Генерирането на реалистично изглеждащи документи или профили на дейности е област, в която **ML има водеща роля**.
- Възходът на **големите езикови модели** като GPT вероятно ще направи процеса на генериране на измамни текстови документи относително лесен за автоматизиране.
- Въпреки че тази технология има огромен потенциал за злоупотреба, защитниците биха могли правдоподобно да я използват за измамни цели, генерирайки вълни от измамни вътрешни документи, за да подведат нападателите.
- Използването на други видове ML модели – като GAN – могат да се приложат за нетекстова измама. Например, изследователите са показали, че е възможно да се използва GAN за генериране на реалистични мрежови данни, които могат да объркат атакуващите.

Приложения на изкуствен интелект за активна защита

- Отвъд фалшификатите, **honeypot** – механизъм за сигурност, предназначен да примамва атакуващ към привлекателни на вид, но фалшиви цели – е дългогодишен измамен инструмент за мрежовите защитници.
- **Honeypots** могат да предложат „примамка“ под формата
  - на фалшиви файлове и данни,
  - да стартират скриптови взаимодействия, за да осуетят противниците,
  - или да подведат нападателите да мислят, че са били по-успешни, отколкото наистина са били.
- *Honeypots* обаче често изискват *ръчно конфигуриране*, внедряване и поддръжка, за да изглеждат като реалистични производствени мрежи достатъчно дълго, за да задържат нападателите, което може да *струва скъпо* и затруднява поддържането им от по-малките организации.

Приложения на изкуствен интелект за активна защита

- Поне от началото на 2000 изследователите са проучвали как ML може да се използва за създаване на по-реалистични и динамични honeypots, включително чрез използване на сравнително прости методи за клъстериране.
- През последните години изследователите експериментират с обучение с утвърждение при използване на honeypots, които могат да се научат
  - да ангажират атакуващите възможно най-дълго, докато също така в идеалния случай ги
  - подмамват да изтеглят персонализиран софтуер на собствените си машини.
- Обучението с утвърждение може да направи различни видове honeypots по-достъпни за по-голям брой организации, като автоматизира голяма част от сложността на поддържането на динамичен honeypot.

Приложения на изкуствен интелект за активна защита

- **Разузнаване на заплахите**
- Събирането на разузнавателна информация за заплахи от потенциални противници теоретично може да позволи на защитниците да предвиждат атаки и да изградят по-силни защити, въпреки че за повечето организации трудоемкият характер на събирането, обработката и анализирането на разузнавателна информация за заплахи го прави непосилно скъп.
- Но тъй като намирането на модели в данните е основната сила на машинното обучение, някои изследователи са проучили как ML и извличането на текст могат да бъдат използвани за подобряване на анализа на разузнаването на заплахи.
- Например, ML методите могат да се използват за групиране на потребители в тъмната мрежа или методите за изучаване на текст могат да бъдат използвани за автоматично събиране, класифициране и анализиране на публикации във форуми и пазари в тъмната мрежа, което позволява на изследователите да идентифицират експлойти от нулев ден, преди да бъдат внедрени.

Приложения на изкуствен интелект за активна защита

- Други инструменти, въведени като измамни тактики, могат да бъдат предназначени за събиране на информация за заплахи от потенциални противници.
- Данните, събрани от honeypot системи, например, могат да бъдат анализирани и съпоставени, за да се определи дали една организация е изправена пред постоянна заплаха, което след това може да се информира за стратегиите за сигурност.
- Фишинг имейли може да се използват като възможност за събиране на данни за заплахи от противник.
- Някои изследователи са предложили системи, които могат да произвеждат подвеждащи отговори на фишинг имейли, за да извлекат информация от нападателите.
- Всъщност това е основна линия на изследване в рамките на инициативата Active Social Engineering Defense в DARPA, която в момента се опитва да изгради системи, които могат да откриват атаки чрез социално инженерство и да реагират автономно, за да подмамят противниците да разкрият идентифицираща информация.

Приложения на изкуствен интелект за активна защита

- **Приписване**
- Когато са изправени пред атака от напреднала постоянна заплаха, федералните агенции и компаниите за киберсигурност обикновено ще положат усилия да припишат атаката на конкретен противник. Това позволява на федералните участници да определят какъв тип отговор е оправдан и помага на компаниите за киберсигурност да определят вероятните мотивации на враждебните участници, за да защитят най-добре своите клиенти.
- Когато се опитват да припишат множество атаки, най-простите подходи разчитат на ръчен анализ на индикатори за атака, получени чрез
  - мрежови регистрационни файлове,
  - защитни стени или
  - honeypots.
- Въпреки това, тъй като повечето упорити кибератаки могат да избегнат оставянето на очевидни модели, приписването също разчита на човешки анализ и разбиране на потенциалните противници и техните всеобхватни цели.
- Следователно, приписването разчита не само на технически, но и на стратегически индикатори и потенциално знания за съответните геополитически ситуации.
- Остава малко вероятно ML да може успешно да автоматизира пълния процес на приписване.

Приложения на изкуствен интелект за активна защита

- Независимо от това, **машинното обучение** все още може да помогне в **процеса на приписване**. Например, ако анализаторите първо извлекат описания на атаката на високо ниво – включително използваните тактики, страната на атаката и т.н. – методите на ML може да са в състояние да групират тази информация, за да идентифицират подобни атаки.
- Обработката на естествен език може да помогне на системите за приписване автоматично да извличат информация, свързана с приписването, от блогове, научни статии и доклади за реакция при инциденти, намалявайки количеството работа, което хората трябва да направят, за да извършат успешно приписване.
- **Прилагането на ML методи към изходния код на атакуващия**, когато е наличен, може да предложи различен път към приписването. Методите на ML вече показаха способността да разграничават и деанонимизират авторите въз основа на техните отличителни стилове на писане.
- През последните години някои изследователи демонстрираха, че генерираният от човека код работи по подобен начин: различни програмисти правят уникален избор, докато програмират, което позволява на машинното обучение да създава цифрови отпечатъци, които да се използват за идентифициране на програмисти.

Обобщение

- **Дълбоко обучение**
  a. Производителността често може да се подобри с повече данни
  b. Може да се използва като основен подход за повечето AI приложения
  c. Моделите често могат автоматично да се научат да извличат подходящи характеристики от данни
- **Обучение с утвърждение**
  a. Позволява на AI агенти, които могат да се научат на стратегическо «мислене»
  b. Може да се комбинира със системи за дълбоко обучение за подобряване на производителността
  c. Не изисква исторически данни, ако могат да бъдат симулирани реалистични среди

Обобщение

- **Генеративни състезателни мрежи**
  a. Може да се комбинира със системи за дълбоко обучение за подобряване на производителността
  b. Може да се използва за разширяване на съществуващи набори от данни или за избягване на съществуващи класификатори
- **Големи езикови модели**
  a. За автоматизиране на генериране на текст, обобщаване и превод, наред с други задачи
  b. Може да се използва за автоматизиране на задачи по сигурността, които включват писмен текст (напр. генериране на доклади за грешки)